



Clasificación automática de células sanguíneas mediante CNN, Batch Normalization y transfer learning

Base experimental: comparación de LeNet-5, VGG-11 simplificado y ResNet-18
Dataset: eosinófilos, linfocitos, monocitos y neutrófilos

Alumno: Pastor Salazar, Tomas Alonso

Profesor: Pinedo Taquila, Jairo

Curso: Introduction to Deep Learning

Resultado principal

El mejor desempeño de test fue ResNet-18 con fine-tuning total: 84,24 %. Frente al mejor modelo entrenado desde cero (71,65 %), representa una mejora de 12.59 puntos porcentuales.

Contenido

1. Resumen ejecutivo
2. Introducción y planteamiento del problema
3. Objetivos del experimento
4. Datos y análisis exploratorio
5. Metodología experimental
6. Resultados comparativos
7. Análisis por tarea
8. Análisis de la matriz de confusión
9. Discusión crítica
10. Conclusiones y recomendaciones
11. Referencias
12. Anexos visuales

1. Resumen ejecutivo

El informe evalúa la clasificación automática de células sanguíneas en cuatro categorías: eosinófilos, linfocitos, monocitos y neutrófilos. Se compararon redes convolucionales entrenadas desde cero, variantes con Batch Normalization y estrategias de transfer learning basadas en ResNet-18. El objetivo no es solamente identificar qué modelo obtiene mayor accuracy, sino interpretar la estabilidad del entrenamiento, la capacidad de generalización y los errores por clase.

Hallazgo	Interpretación
Mejor modelo global	ResNet-18 con fine-tuning total alcanzó 84.24% de accuracy en test.
Mejor modelo desde cero	VGG-11 simplificado con Batch Normalization alcanzó 71.65% en test, superando claramente a VGG-11 sin BN.
Efecto de Batch Normalization	BN fue decisivo en VGG-11 con LR=0.001, pero no garantizó mejora en LeNet ni estabilidad con LR=0.01.
Riesgo de sobreajuste	ResNet-18 parcial y total llegaron a 99.67% en validación, pero test fue menor; esto sugiere revisar particiones, semillas y validación externa.
Error clínicamente relevante	Los errores se concentran en predicciones hacia neutrófilo, especialmente desde monocitos y eosinófilos; por eso conviene reportar métricas por clase.

2. Introducción y planteamiento del problema

El análisis morfológico de células sanguíneas es una tarea frecuente en laboratorios clínicos. Aunque la decisión médica final debe seguir siendo responsabilidad del personal especializado, los modelos de visión computacional pueden servir como apoyo para preclasificación, tamizaje, priorización de muestras y reducción de carga operativa. En este contexto, la clasificación automática de imágenes microscópicas requiere modelos capaces de reconocer patrones visuales finos, como tamaño nuclear, coloración, granularidad y forma celular.

La dificultad principal es que varias clases pueden presentar similitudes visuales o variaciones intra-clase. Además, cuando el conjunto de datos es limitado, entrenar redes profundas desde cero puede producir baja generalización. Por ello, el informe compara tres enfoques: modelos convolucionales clásicos entrenados desde cero, incorporación de Batch Normalization y transferencia de aprendizaje mediante ResNet-18.

3. Objetivos del experimento

Objetivo general

Comparar el desempeño de modelos convolucionales y de transfer learning para la clasificación automática de células sanguíneas en cuatro clases, evaluando accuracy, estabilidad del entrenamiento, costo computacional y errores por clase.

Objetivos específicos

- Entrenar y comparar LeNet-5 adaptado y VGG-11 simplificado desde cero.
- Analizar el efecto de Batch Normalization bajo condiciones controladas y con una tasa de aprendizaje alta.
- Evaluar ResNet-18 mediante feature extraction, fine-tuning parcial y fine-tuning total.
- Interpretar la matriz de confusión del mejor modelo para identificar clases fáciles, clases difíciles y errores dominantes.
- Formular recomendaciones técnicas para mejorar la robustez del modelo antes de un uso real en contexto médico.

4. Datos y análisis exploratorio

El dataset contiene imágenes RGB distribuidas en cuatro clases: eosinófilos, linfocitos, monocitos y neutrófilos. La distribución observada en entrenamiento y prueba es balanceada, aproximadamente 2 500 imágenes por clase en TRAIN y cerca de 620 por clase en TEST. Esta condición permite usar accuracy como métrica inicial, aunque no reemplaza el análisis por clase, especialmente en aplicaciones médicas.

Las muestras visuales muestran que el problema no es trivial: algunas células comparten coloraciones y formas similares, mientras que otras presentan patrones más distintivos. Esta similitud explica por qué el análisis de errores es tan importante como el accuracy promedio.

EDA




Figura 1. Distribución de clases y muestras por clase generadas en el notebook 01_edu.ipynb.

5. Metodología experimental

Las imágenes se redimensionaron a 64 x 64 píxeles para LeNet-5 y VGG-11, y a 224 x 224 píxeles para los modelos preentrenados. Se aplicó normalización compatible con ImageNet, aumento de datos simple en entrenamiento mediante RandomHorizontalFlip y RandomRotation(10), función de pérdida CrossEntropyLoss y optimizador AdamW. El conjunto TRAIN se dividió en entrenamiento y validación con val_split=0.15, mientras que TEST se reservó para la evaluación final.

Bloque experimental	Modelos evaluados	Propósito
Tarea 1: modelos desde cero	LeNet-5, LeNet-5+BN, VGG-11, VGG-11+BN	Medir capacidad de aprendizaje desde cero y estabilidad de curvas.
Tarea 2: Batch Normalization	VGG-11 vs VGG-11+BN con LR=0.001 y LR=0.01	Aislar el efecto de BN manteniendo arquitectura y entrenamiento comparables.
Tarea 3: transfer learning	ResNet-18 feature extraction, parcial y total	Evaluar si las representaciones preentrenadas mejoran desempeño con datos limitados.

6. Resultados comparativos

La siguiente tabla reorganiza los resultados principales. Los porcentajes se reportan sobre validación y test. La columna de lectura resume el comportamiento más importante de cada modelo.

Modelo	Enfoque	Val. acc.	Test acc.	Tiempo/época	Ép. 80% val.
LeNet-5 adaptado	Entrenado desde cero	83,12 %	66,75 %	30.47 s	9
LeNet-5 + BN	Entrenado desde cero	80,78 %	60,27 %	31.48 s	8
VGG-11 simplificado	Entrenado desde cero	25,92 %	24,93 %	28.65 s	No alcanza
VGG-11 simplificado + BN	Entrenado desde cero	83,39 %	71,65 %	27.48 s	10
VGG-11 LR alta	Entrenado desde cero	25,92 %	24,93 %	28.06 s	No alcanza
VGG-11 + BN LR alta	Entrenado desde cero	25,92 %	24,93 %	26.36 s	No alcanza
ResNet-18 feature extraction	Transfer learning	57,33 %	46,60 %	46.47 s	No alcanza
ResNet-18 fine-tuning parcial	Transfer learning	99,67 %	81,22 %	55.51 s	1
ResNet-18 fine-tuning total	Transfer learning	99,67 %	84,24 %	67.04 s	1

- ResNet-18 con fine-tuning total obtiene el mayor accuracy en test y supera al mejor modelo desde cero por 12,59 puntos porcentuales.
- VGG-11 sin Batch Normalization se mantiene cerca del azar; VGG-11+BN sí aprende y se convierte en el mejor modelo entrenado desde cero.
- LeNet-5+BN alcanza antes el 80 % de validación, pero generaliza peor que LeNet-5 sin BN.
- Feature extraction no adapta suficientemente el modelo al dominio celular; el ajuste parcial o total es necesario.
- Los modelos con LR=0,01 quedan cerca del azar, lo que indica que la tasa de aprendizaje alta fue inadecuada.




Figura 2. Accuracv en test por modelo. ResNet-18 con fine-tuning total logra el mejor desempeño final.




Figura 3. Brecha entre validación y test. Las brechas altas sugieren posible sobreajuste o diferencia entre particiones.

7. Análisis por tarea

7.1 Tarea 1: modelos entrenados desde cero

LeNet-5 adaptado obtiene 66.75% en test, lo que indica que una arquitectura pequeña puede capturar patrones básicos del dataset. Sin embargo, su capacidad de representación es limitada. La variante LeNet-5+BN alcanza el umbral de 80% en validación una época antes, pero su accuracv de test cae a 60.27%; por tanto, en esta arquitectura BN acelera parcialmente el aprendizaje, pero no mejora la generalización.

El caso de VGG-11 es más claro: sin BN permanece alrededor de 24.93% en test, cercano al azar para cuatro clases. Con BN, VGG-11 sube a 71.65% en test. Esto sugiere que una red más profunda entrenada desde cero necesita estabilización de activaciones para aprender adecuadamente en este experimento.

Tarea 1: modelos desde cero




Figura 4. Curvas de pérdida y exactitud de LeNet, LeNet+BN, VGG-11 y VGG-11+BN.

7.2 Tarea 2: efecto de Batch Normalization

La comparación controlada entre VGG-11 y VGG-11+BN con LR=0.001 muestra que Batch Normalization reduce la pérdida de entrenamiento y permite que la red supere el estancamiento observado en VGG-11 sin BN. No obstante, la prueba con LR=0.01 muestra que BN no es una solución universal: ambas variantes quedan cerca del azar, por lo que la tasa de aprendizaje alta resultó perjudicial.

La conclusión correcta no es que BN siempre aumenta el accuracy, sino que puede facilitar la optimización cuando la arquitectura y el learning rate están razonablemente configurados. En este experimento, su efecto más sólido aparece en VGG-11 con LR=0.001.

Tarea 2: Batch Normalization




Figura 5. Comparación del efecto de Batch Normalization en configuración controlada y con learning rate alto.

7.3 Tarea 3: transfer learning con ResNet-18

El transfer learning ofrece los mejores resultados del experimento. Feature extraction obtiene 46.60% en test, lo cual indica que congelar casi todo el modelo no es suficiente para adaptar representaciones de ImageNet al dominio de células sanguíneas. En cambio, el fine-tuning parcial alcanza 81.22% y el fine-tuning total 84.24% en test.

La diferencia entre fine-tuning parcial y total es de 3.02 puntos porcentuales a favor del entrenamiento total. Sin embargo, el costo medio por época también aumenta: 55.51 s en parcial frente a 67.04 s en total. Por eso, si el criterio principal es el máximo desempeño, conviene elegir fine-tuning total; si se busca un equilibrio entre desempeño, costo y menor riesgo de sobreajuste, el fine-tuning parcial es una alternativa muy defendible.

Tarea 3: imagenes del notebook 03_transfer




Figura 6. Curvas del mejor modelo de transfer learning: ResNet-18 con fine-tuning total.

7. Análisis de la matriz de confusión

La matriz de confusión del mejor modelo contiene 2487 imágenes de prueba y una exactitud global de 84,24 %. El comportamiento no es uniforme entre clases: linfocito se clasifica perfectamente en la prueba, mientras que las principales confusiones ocurren hacia la clase neutrófilo.

Clase real \ predicha	Eosinófilo	Linfocito	Monocito	Neutrófilo
Eosinófilo	492	0	0	131
Linfocito	0	620	0	0
Monocito	16	0	438	166
Neutrófilo	79	0	0	545

Clase	Soporte	Precisión	Recall / sensibilidad	Especificidad	F1-score
Eosinófilo	623	83,82 %	78,97 %	94,90 %	81,32 %
Linfocito	620	100,00 %	100,00 %	100,00 %	100,00 %
Monocito	620	100,00 %	70,65 %	100,00 %	82,80 %
Neutrófilo	624	64.73 %	87.34 %	84.06 %	74.35 %

El F1 macro es 84,62 % y el F1 ponderado es 84,60 %. La precisión de neutrófilo es la más baja (64,73 %), porque muchos eosinófilos y monocitos son etiquetados como neutrófilos. El recall de monocito también es bajo en comparación con las demás clases, ya que 166 monocitos fueron clasificados como neutrófilos.

- Linfocito es la clase más estable: no presenta errores en la matriz de prueba.
- Eosinófilo tiene 131 errores hacia neutrófilo, lo que reduce su sensibilidad.
- Monocito tiene 166 errores hacia neutrófilo y 16 hacia eosinófilo; es una clase que requiere mejora.
- Neutrófilo tiene recall alto, pero precisión moderada, porque recibe predicciones falsas de otras clases.




Figura 7. Matriz de confusión del mejor modelo, ResNet-18 con fine-tuning total.

9. Discusión crítica

9.1 Interpretación técnica

Los resultados apoyan tres conclusiones técnicas. Primero, las redes pequeñas pueden funcionar como línea base, pero su techo de rendimiento es menor. Segundo, las redes más profundas entrenadas desde cero pueden fallar si no se estabiliza el entrenamiento. Tercero, el transfer learning mejora significativamente el desempeño cuando se permite adaptar capas profundas al nuevo dominio.

El mejor resultado de validación de ResNet-18 parcial y total es 99.67%, pero el test queda en 81.22% y 84.24%. Esta brecha no invalida el resultado, pero exige cautela: puede indicar sobreajuste, diferencias entre validación y test, o que la validación no representa completamente la dificultad de la prueba final.

Observación importante sobre el learning rate

En la tabla original, el learning rate de ResNet-18 fine-tuning total aparece como 0.0. Si realmente fuera cero, el modelo no debería actualizar pesos. Lo más probable es que sea un problema de redondeo o registro del CSV. Se recomienda guardar el LR en notación científica, por ejemplo 1e-5.

9.2 Limitaciones del experimento

- Se reporta una sola corrida por configuración; para conclusiones más robustas conviene repetir con varias semillas y promediar resultados.
- No se observa validación externa con imágenes provenientes de otro laboratorio, microscopio o protocolo de tinción.
- El accuracy global puede ocultar errores por clase; en contexto médico se deben priorizar recall, precisión, F1 y curvas ROC/PR por clase.
- El redimensionamiento a 64 x 64 en modelos desde cero puede eliminar detalles morfológicos útiles.
- Las técnicas de aumento de datos usadas son básicas; podrían probarse transformaciones controladas de brillo, contraste, enfoque y coloración, cuidando no alterar rasgos diagnósticos.

10. Conclusiones y recomendaciones

1. ResNet-18 con fine-tuning total es el mejor modelo según accuracy en test, con 84.24%.
2. ResNet-18 con fine-tuning parcial es el mejor compromiso si se busca reducir costo y riesgo de sobreajuste, manteniendo un desempeño alto de 81.22%.
3. Batch Normalization mejora de forma clara el entrenamiento de VGG-11 con LR=0.001, pero no garantiza mejoras en todas las arquitecturas ni con tasas de aprendizaje excesivas.
4. El análisis de la matriz de confusión muestra que el modelo necesita mejorar la separación entre monocitos, eosinófilos y neutrófilos.
5. Antes de considerar un uso clínico, se debe validar el modelo con datos externos, repetir experimentos con varias semillas y reportar métricas por clase.

Recomendaciones de mejora

- Corregir el registro del learning rate de ResNet-18 fine-tuning total para evitar que aparezca como 0.0.
- Incluir métricas adicionales: precisión, sensibilidad, especificidad, F1 macro, F1 ponderado y reporte por clase.
- Probar fine-tuning gradual: descongelar bloques progresivamente y usar learning rates diferenciados por capa.
- Aplicar early stopping, reducción de learning rate por plateau y guardado del mejor checkpoint por validación.
- Realizar validación cruzada o, al menos, varias corridas con semillas distintas.
- Aumentar datos de forma controlada para mejorar la robustez frente a cambios de iluminación, tinción y orientación celular.
- Si el objetivo es una herramienta de apoyo médico, definir umbrales de confianza y una categoría “revisar por especialista” para predicciones inciertas.


11. Referencias

- Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). ImageNet: A Large-Scale Hierarchical Image Database. IEEE Conference on Computer Vision and Pattern Recognition.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. IEEE Conference on Computer Vision and Pattern Recognition.
- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. International Conference on Machine Learning.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems.
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. Proceedings of the IEEE.
- Simonyan, K., & Zisserman, A. (2015). Very Deep Convolutional Networks for Large-Scale Image Recognition. International Conference on Learning Representations.
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? Advances in Neural Information Processing Systems.

11. Anexos visuales


A continuación se conservan las figuras generadas por los notebooks, integradas al documento para facilitar la edición y sustentación del informe.

Tarea 1: modelos desde cero




Anexo A. Curvas de entrenamiento de los modelos desde cero.

Tarea 2: Batch Normalization




Anexo B. Comparación de Batch Normalization bajo LR controlada y LR alta.

Tarea 3: imagenes del notebook 03_transfer



Anexo C. Curvas de ResNet-18 fine-tuning total.

Matriz de confusion del mejor modelo



Anexo D. Matriz de confusión del mejor modelo.

Anexo E. Tabla completa de métricas del experimento

Modelo	Parámetros	Entrenables	Tiempo/época	Best val acc.	Test acc.	Ép. 80% val.	LR
LeNet	337 976	337 976	30.4725	0.8312	0.6675	9	0.001
LeNet+BN	338 020	338 020	31.4794	0.8078	0.6027	8	0.001
VGG-11	3 095 748	3 095 748	28.6497	0.2592	0.2493	No alcanza	0.001
VGG-11+BN	3 098 500	3 098 500	27.4764	0.8339	0.7165	10	0.001
VGG-11 LR alta	3 095 748	3 095 748	28.0572	0.2592	0.2493	No alcanza	0.01
VGG-11+BN LR alta	3 098 500	3 098 500	26.3590	0.2592	0.2493	No alcanza	0.01
R18 feature	11 178 564	11 178 564	46.4728	0.5733	0.4660	No alcanza	0.0001
R18 parcial	11 178 564	11 178 564	55.5124	0.9967	0.8122	1	0.0001
R18 total	11 178 564	11 178 564	67.0447	0.9967	0.8424	1	0.0*

*Nota: el valor 0.0 del learning rate en resnet18_full debe verificarse en el archivo de resultados, porque podría deberse a redondeo del CSV o del reporte.